



UNIVERSIDAD AUTÓNOMA DEL CARMEN

FACULTAD CIENCIAS DE LA INFORMACIÓN
ING. EN SISTEMAS COMPUTACIONALES



MATERIA:

PROGRAMACION AVANZADA

PROFESOR:

JESUS ALEJANDRO FLORES HERNANDEZ

ALUMNOS:

RUDY SALDAÑA MERENCIANO

ISAIAS EMMANUEL POOT ORLAINETA

CRISTOFER EMMANUEL DE LA CRUZ APARICIO



1. Introducción y Marco Teórico

El algoritmo **ID3** (Iterative Dichotomiser 3) es un método de aprendizaje supervisado utilizado para la construcción de árboles de decisión a partir de un conjunto de datos. Su principio fundamental se basa en la Teoría de la Información de Claude Shannon, buscando en cada nodo seleccionar el atributo que genere la mayor reducción de incertidumbre respecto a la variable objetivo (clase). El algoritmo original solo trabaja con atributos nominales (categóricos) y no realiza poda (*pruning*), por lo que tiende a generar árboles exhaustivos que pueden sufrir de sobreajuste (*overfitting*).

Para desarrollar la toma de decisiones del algoritmo, se utilizan las siguientes métricas fundamentales:

1.1 Entropía General del Conjunto (S)

Mide la cantidad de impureza o incertidumbre en el conjunto de datos actual respecto a un conjunto de c clases objetivo.

$$Entropia(S) = - \sum_{i=1}^c p_i \log_2(p_i)$$

Donde p_i representa la proporción de instancias pertenecientes a la clase i dentro del subconjunto S , es decir, $p_i = \frac{|S_i|}{|S|}$.

1.2 Entropía Específica de una División (Atributo A)

Evalúa la impureza remanente después de dividir el conjunto de datos S utilizando los distintos valores v de un atributo A .

$$Entropia_A(S) = \sum_{v \in \text{Valores}(A)} \frac{|S_v|}{|S|} Entropia(S_v)$$



UNIVERSIDAD AUTÓNOMA DEL CARMEN



FACULTAD CIENCIAS DE LA INFORMACIÓN ING. EN SISTEMAS COMPUTACIONALES

1.3 Ganancia de Información

Es la métrica de decisión principal de ID3. Cuantifica la reducción esperada de la entropía (incertidumbre) al particionar los datos según el atributo A . El algoritmo seleccionará siempre el atributo que maximice esta métrica.

$$Gain(S, A) = Entropia(S) - Entropia_A(S)$$

$$Gain(S, A) = Entropia(S) - \sum_{v \in Valores(A)} \frac{|S_v|}{|S|} Entropia(S_v)$$

2. Datos y Discretización Utilizados

Se utiliza el archivo iris.data.csv (150 observaciones, alojado en el directorio actividad01.arboles/) como fuente de datos. Dado que la versión estándar de ID3 solo admite atributos nominales, se aplicó un proceso de discretización a los 4 atributos numéricos continuos.

El método utilizado fue el de **discretización por igual anchura de intervalo** (*Equal-width binning*), dividiendo el rango de cada atributo en 3 categorías discretas: "chico", "mediano" y "grande".

Fórmulas de Discretización:

Para encontrar los umbrales de corte, primero se calcula el ancho del intervalo (W) en función del valor máximo y mínimo del atributo en el conjunto de datos:

$$W = \frac{Max - Min}{3}$$

A partir de W , se definen los umbrales:

- $Umbral_1 = Min + W$
- $Umbral_2 = Min + 2W$

Criterios de Asignación:

- **Chico:** $Valor \leq Umbral_1$



UNIVERSIDAD AUTÓNOMA DEL CARMEN



FACULTAD CIENCIAS DE LA INFORMACIÓN ING. EN SISTEMAS COMPUTACIONALES

- Mediano: $Umbral_1 < Valor \leq Umbral_2$
- Grande: $Valor > Umbral_2$

Tabla de Umbrales Calculados:

Atributo	Mínimo	Máximo	Umbral 1	Umbral 2
sepal	4.3	7.9	5.5	6.7
sepalw	2.0	4.4	2.8	3.6
petal	1.0	6.9	2.967	4.933
petalw	0.1	2.5	0.9	1.7

3. Desarrollo del Procedimiento: Cálculo en el Nodo Raíz

En el nodo raíz, analizamos el conjunto de entrenamiento completo (S). La clase objetivo (especie) tiene 3 valores perfectamente balanceados: 50 *Iris-setosa*, 50 *Iris-versicolor* y 50 *Iris-virginica* ($N_{total} = 150$).

Paso 3.1: Entropía Inicial

Calculamos la entropía del conjunto completo usando la fórmula 1.1:

$$Entropia(S) = - \left(\frac{50}{150} \log_2 \left(\frac{50}{150} \right) + \frac{50}{150} \log_2 \left(\frac{50}{150} \right) + \frac{50}{150} \log_2 \left(\frac{50}{150} \right) \right)$$

$$Entropia(S) = -3 \times \left(\frac{1}{3} \log_2 \left(\frac{1}{3} \right) \right)$$

$$Entropia(S) = -\log_2 \left(\frac{1}{3} \right) = \log_2(3) \approx 1.5850 \text{ bits}$$

Al ser un conjunto perfectamente distribuido en 3 clases, la incertidumbre es máxima (



1.5850).

Paso 3.2: Cálculo de Ganancia para petalw

Para saber qué atributo elegir, ID3 calcula la ganancia de los 4. Desarrollemos matemáticamente el cálculo para el ancho del pétalo (petalw), el cual divide el conjunto S en tres subconjuntos (S_{chico} , $S_{mediano}$, S_{grande}).

1. **Rama petalw = chico:** Contiene 50 instancias, todas pertenecientes a setosa.

$$Entropia(S_{chico}) = - \left(\frac{50}{50} \log_2(1) \right) = 0 \text{ bits}$$

2. **Rama petalw = mediano:** Contiene 54 instancias (49 versicolor, 5 virginica).

$$Entropia(S_{mediano}) = - \left(\frac{49}{54} \log_2 \left(\frac{49}{54} \right) + \frac{5}{54} \log_2 \left(\frac{5}{54} \right) \right) \approx 0.4451 \text{ bits}$$

3. **Rama petalw = grande:** Contiene 46 instancias (1 versicolor, 45 virginica).

$$Entropia(S_{grande}) = - \left(\frac{1}{46} \log_2 \left(\frac{1}{46} \right) + \frac{45}{46} \log_2 \left(\frac{45}{46} \right) \right) \approx 0.1511 \text{ bits}$$

Calculamos la Entropía Específica Ponderada de petalw:

$$Entropia_{petalw}(S) = \left(\frac{50}{150} \times 0 \right) + \left(\frac{54}{150} \times 0.4451 \right) + \left(\frac{46}{150} \times 0.1511 \right)$$

$$Entropia_{petalw}(S) = 0 + 0.1602 + 0.0463 \approx 0.2066 \text{ bits}$$

Finalmente, calculamos la Ganancia de Información:

$$Gain(S, petalw) = 1.5850 - 0.2066 = 1.3784 \text{ bits}$$



UNIVERSIDAD AUTÓNOMA DEL CARMEN



FACULTAD CIENCIAS DE LA INFORMACIÓN ING. EN SISTEMAS COMPUTACIONALES

Paso 3.3: Resultados de Ganancia en la Raíz

Repitiendo el procedimiento iterativo para el resto de los atributos, obtenemos:

Atributo	Ganancia de Información Gain(S,A)	Resultado
petalw	1.3784	<<< SE ELIGE (Máxima Ganancia)
petall	1.3247	
sepall	0.6122	
sepalw	0.2659	

4. Segundo Nivel del Árbol

Como petalw fue elegido como nodo raíz, se generan tres ramas derivadas de sus valores discretizados:

1. **Rama petalw = chico:** Resulta pura (Entropía = 0, contiene solo las 50 instancias de setosa). Se convierte inmediatamente en un nodo **hoja**.
2. **Rama petalw = mediano:** ($n = 54$, $Entropia = 0.4451$, Distribución = {versicolor: 49, virginica: 5}). Al no ser pura, se calcula la ganancia para los atributos restantes evaluando solo estas 54 instancias.
 - Ganancias: petall = 0.2132 | sepalw = 0.0167 | sepall = 0.0126.
 - **Atributo elegido:** petall.
3. **Rama petalw = grande:** ($n = 46$, $Entropia = 0.1511$, Distribución = {versicolor: 1, virginica: 45}). Se repite el proceso recursivo.
 - Ganancias: petall = 0.0663 | sepalw = 0.0147 | sepall = 0.0136.
 - **Atributo elegido:** petall.

5. Árbol ID3 Completo (Sin Poda)

El proceso de cálculo de entropía y ganancia de información se repite recursivamente hasta agotar los atributos explicativos o hasta llegar a subconjuntos completamente puros (

$Entropia = 0$). El árbol resultante alcanza **4 niveles de profundidad** y genera **11 hojas efectivas**.



UNIVERSIDAD AUTÓNOMA DEL CARMEN



FACULTAD CIENCIAS DE LA INFORMACIÓN ING. EN SISTEMAS COMPUTACIONALES

La siguiente estructura representa el árbol inducido:


- **petalw = chico:** => **setosa** (50)
- **petalw = mediano:**
 - petall = chico: => (Sin ejemplos -> hereda clase mayoritaria: versicolor)
 - petall = mediano:
 - sepall = chico:
 - sepalw = chico: => **versicolor** (11)
 - sepalw = mediano: => **versicolor** (1)
 - sepalw = grande: => (Sin ejemplos -> hereda versicolor)
 - sepall = mediano: => **versicolor** (33)
 - sepall = grande: => **versicolor** (3)
 - petall = grande:
 - sepall = chico: => (Sin ejemplos -> hereda virginica)
 - sepall = mediano:
 - sepalw = chico: => **virginica** (4)
 - sepalw = mediano: => **versicolor** (1)
 - sepalw = grande: => (Sin ejemplos -> hereda virginica)
 - sepall = grande: => **virginica** (1)
- **petalw = grande:**
 - petall = chico: => (Sin ejemplos -> hereda virginica)
 - petall = mediano:
 - sepalw = chico: => **virginica** (3)
 - sepalw = mediano:
 - sepall = chico: => (Sin ejemplos -> hereda virginica)
 - sepall = mediano: => **virginica** (3)
 - sepall = grande: => (Sin ejemplos -> hereda virginica)
 - sepalw = grande: => (Sin ejemplos -> hereda virginica)
 - petall = grande: => **virginica** (40)



UNIVERSIDAD AUTÓNOMA DEL CARMEN



FACULTAD CIENCIAS DE LA INFORMACIÓN ING. EN SISTEMAS COMPUTACIONALES



Nota Analítica: La presencia de numerosas hojas basadas en escasas instancias (1 o 3 casos) es la manifestación directa del sobreajuste empírico del ID3 al carecer de poda.

6. Evaluación del Árbol sobre el Set de Entrenamiento

Dado que ID3 convencional no separa datos de prueba por sí mismo en este ejercicio, procedemos a re-evaluar las 150 instancias originales empleando las reglas deducidas en la Sección 5. El modelo logra clasificar correctamente 147 de las 150 instancias, arrojando una **exactitud del 98.00%**.

Matriz de Confusión:

Predicción \ Real	Setosa	Virginica	Versicolor
-------------------	--------	-----------	------------



UNIVERSIDAD AUTÓNOMA DEL CARMEN



FACULTAD CIENCIAS DE LA INFORMACIÓN ING. EN SISTEMAS COMPUTACIONALES

Setosa	50	0	0
Virginica	0	49	2
Versicolor	0	1	48

Como se observa en la matriz de confusión, los únicos errores del algoritmo ocurren en la frontera de decisión entre las especies *versicolor* y *virginica* (1 falso versicolor, 2 falsos virginica). Esto tiene coherencia biológica y matemática, ya que estas dos especies presentan una superposición en las dimensiones de sus sépalos y pétalos, a diferencia de la especie *setosa*, la cual es linealmente separable y alcanza una precisión del 100%.

7. Conclusiones

- Poder Predictivo de los Atributos:** De acuerdo con la métrica de Ganancia de Información basada en entropía, el atributo con mayor poder discriminativo para separar las especies de Iris es el ancho del pétalo (petalw , $\text{Gain} \approx 1.378$), seguido por el largo del pétalo (petall). Ambos superan holgadamente el impacto explicativo de las medidas del sépalo.
- Rendimiento y Limitaciones:** Aunque el algoritmo ID3 puro es capaz de generar reglas con una exactitud sobresaliente del 98.00% sobre el propio conjunto de entrenamiento, la complejidad geométrica del árbol (11 hojas activas y ramificaciones profundas por 1 solo caso) evidencia un problema inherente de sobreajuste (*overfitting*). Comparado con iteraciones más avanzadas como C4.5/J48, la ausencia de una fase de poda (*post-pruning*) penaliza la capacidad de generalización del modelo.